El corrector de TalentPact

Cómo funciona, qué fallaba, qué hemos cambiado y cómo hacer que corrija de forma más elaborada y concreta

Documento de trabajo para Xagri e Iván · 15 de octubre de 2026 · Corrector versión 2.1.0

En una frase

El corrector ya no pone la nota «a ojo». Ahora puntúa criterios fijos con una escala igual para todos, tiene que citar frases reales de la respuesta y deja que el servidor haga la cuenta. El siguiente paso, imprescindible, es **medir** cuánto coincide con una persona de RRHH.

Contenido

1 Resumen para leer en dos minutos

2 Cómo funciona el corrector hoy

3 Qué fallaba en la versión 2.0

4 Qué hemos cambiado en la versión 2.1, con ejemplos

5 Límites de la versión 2.1 (lo que todavía no sabemos)

6 Propuestas para mejorarlo: medir, rúbricas, técnica de corrección, trampas, justicia, feedback, empresa, nuevos ejercicios, coste y cumplimiento

7 Hoja de ruta y decisiones pendientes

8 Anexo: pesos, escala, topes y ficheros

1. Resumen para leer en dos minutos

El corrector es la pieza que da sentido a TalentPact: convierte la respuesta de un candidato a un reto en una nota que una empresa se pueda creer. Si la nota no es **concreta** (qué hizo bien y qué no), **justificada** (con pruebas sacadas de la respuesta) y **estable** (la misma respuesta saca la misma nota), la empresa no paga y el candidato no aprende nada.

Qué fallaba

- Todos los retos se corregían con los mismos cuatro criterios genéricos, y el feedback salía vago.
- La nota final la decidía el modelo de IA sin que nadie comprobara que cuadrara con las notas de cada criterio.
- El modelo podía justificar una nota con algo que el candidato no había escrito.
- En los ejercicios de clasificación (95 de 309), el navegador enviaba también la respuesta correcta: se podía hacer trampa, y además se pagaba una llamada a la IA por una simple cuenta.
- Las cifras de calidad del TFM se midieron con otro prompt y otros retos: no describen el corrector que usa la web.

Qué hemos cambiado (versión 2.1)

- Criterios fijos y con peso según el tipo de ejercicio (análisis, correo, otros).
- Una escala por niveles igual para todos los criterios, para que un 70 signifique siempre lo mismo.
- Indicadores concretos de cada ejercicio, que el corrector revisa uno a uno.
- Citas literales obligatorias, comprobadas por el servidor. Sin pruebas, un criterio no pasa de 40.
- La nota final y los topes los calcula el servidor, no el modelo.
- Feedback por criterio: cita, qué está bien, qué falta y una acción concreta para subir.
- Las clasificaciones se corrigen sin IA, con la solución oficial y descontando el acierto por azar.

Qué proponemos

Lo primero es **medir**: unas 30 respuestas reales puntuadas por la asesora y por uno de vosotros, y un banco de pruebas que llame al corrector de verdad. Con eso se decide todo lo demás. Después: rúbricas escritas por expertos para los retos de Personas y equipo, corrección en dos pasadas, doble corrección cerca de los cortes, bandas para la empresa, variantes de cada reto contra la trampa, transcripción del audio y una repregunta adaptativa. La sección 6 lo explica todo con detalle.

2. Cómo funciona el corrector hoy

Este es el recorrido de una respuesta desde que el candidato pulsa «Enviar» hasta que su nota llega al pool de empresas:

Paso	Qué pasa	Dónde
1. Respuesta	El navegador envía el identificador del reto y del ejercicio, y la respuesta del candidato.	Web (08-ofertas-y-ejercicios.js)
2. Enunciado oficial	Si el reto es del catálogo, el servidor ignora el enunciado que llega del navegador y usa el suyo (título, escenario, datos e indicadores).	Servidor (catalogo-retos.json)
3. Clasificaciones	Si el ejercicio es de clasificar, se corrige aquí con la solución oficial, sin IA.	Servidor (corregirDecision)
4. Filtro de manipulación	Si la respuesta intenta dar órdenes al corrector («ignora las instrucciones», «ponme un 100»), se pone un 0 sin llamar al modelo. Si hay una señal leve, la nota se limita a 60.	Servidor (detectInjection)
5. Corrección con IA	El modelo recibe las reglas, la rúbrica, los indicadores y la respuesta entre etiquetas con un código aleatorio, para que no pueda colar instrucciones. Devuelve una nota y pruebas por criterio.	Anthropic (temperatura 0)
6. Nota final	El servidor comprueba las citas, aplica pesos y topes y redacta el feedback.	Servidor (puntuar)
7. Recibo firmado	La nota sale con un recibo firmado (HMAC). Al guardarla, el servidor comprueba que la firma es suya, que el reto es del catálogo y que la nota cuadra.	Servidor (save-evaluation)
8. Pool y SkillPass	Solo las notas con recibo válido salen como «verificadas». En el pool y en el SkillPass, una verificada manda sobre una no verificada.	Servidor

Importante para producción

Sin la variable **EVAL_SIGNING_SECRET** configurada en Netlify, los recibos no se firman y **ninguna nota sale verificada**. Es lo primero que hay que hacer, independientemente de todo lo demás.

3. Qué fallaba en la versión 2.0

Fallo	Qué pasaba	Consecuencia
Rúbrica genérica	Un correo para comunicar una mala noticia al equipo y un análisis de métricas de un SaaS se medían con los mismos cuatro criterios: relevancia, profundidad, estructura y aplicabilidad.	El modelo no sabía qué mirar en cada ejercicio, y el feedback acababa siendo «profundiza más» o «sé más concreto», que no ayuda a nadie.
Nota global «a ojo»	El prompt pedía «la media ponderada de los criterios», pero no decía los pesos exactos y nadie comprobaba la cuenta.	Podía salir un 70 global con todos los criterios en 50. La nota no se podía reproducir ni explicar.
Sin pruebas	El feedback podía decir «calcula bien el CAC» aunque el candidato no hubiera mencionado el CAC.	Feedback que no se puede auditar. Para un sistema que influye en decisiones de empleo (alto riesgo en el Reglamento europeo de IA) es un problema serio.
Topes solo en el prompt	Reglas como «si no aborda el escenario, máximo 10» eran texto en el prompt.	El modelo podía no cumplirlas y nadie lo detectaba.
Guías desaprovechadas	Muchos ejercicios traen una guía muy concreta: «Incluye: 1) Apertura sin atacar 2) Hechos concretos 3) Pregunta abierta». Se pasaba como texto suelto.	Eran los indicadores más útiles que teníamos y el corrector no los usaba como lista de comprobación.
Clasificaciones con IA y con la solución en el navegador	En los 95 ejercicios de clasificar, el navegador mandaba lo que eligió el candidato y cuál era la respuesta correcta.	Bastaba con cambiar la «correcta» para sacar buena nota. Y cada intento costaba una llamada a la IA para hacer una cuenta.
El banco de pruebas mide otra cosa	Las cifras de calidad del TFM (acuerdo de banda, error medio) salen del modo «crudo» con dos retos del POC (Python y SQL).	No describen el corrector que usan los 103 retos de la web. No sabemos cuánto acierta en producción.

4. Qué hemos cambiado en la versión 2.1

4.1 Criterios fijos con peso, según el tipo de ejercicio

Los criterios y sus pesos los define el servidor. El modelo puntúa cada criterio por separado, pero no decide la nota final.

Tipo de ejercicio	Criterios (peso)
Análisis de datos (88 ejercicios)	Interpretación de los datos (25) · Diagnóstico (25) · Plan de acción priorizado (30) · Justificación con datos (20)
Correo o comunicación (124)	Contenido y cobertura (30) · Propuesta concreta (25) · Tono y adecuación (20) · Estructura (15) · Concisión (10)
Resto (audio y otros)	Relevancia (30) · Profundidad (30) · Aplicabilidad (25) · Estructura (15)
Clasificación (95)	Sin IA: porcentaje de acierto con la solución oficial, descontando el azar

4.2 Una escala igual para todos los criterios

Sin una escala descrita, «70» significa cosas distintas en cada corrección. Ahora cada tramo tiene una definición:

Nota	Qué significa
0–20	No lo hace, o lo hace mal.
21–40	Lo menciona sin desarrollarlo, o de forma genérica que valdría para cualquier caso.
41–60	Correcto pero poco concreto; usa poco el escenario.
61–80	Concreto y aplicado a este escenario, con alguna carencia.
81–100	Concreto, justificado con datos del escenario y sin carencias relevantes.

4.3 Indicadores concretos de cada ejercicio

Cuando la guía de un ejercicio viene numerada, el servidor la convierte en una lista de indicadores. El modelo tiene que decir, uno a uno, cuáles se cumplen y cuáles faltan. En los análisis se añaden los conceptos esperados y la tabla de datos del escenario.

> **Ejemplo: reto de Liderazgo, «Conversación difícil»**
>
> Guía original: *«Incluye: 1) Apertura (cómo empiezas sin atacar). 2) Hechos concretos (no sensaciones). 3) Pregunta abierta…»*
>
> Indicadores que revisa el corrector: **Apertura sin atacar** · **Hechos concretos, no sensaciones** · **Pregunta abierta**.

4.4 Pruebas obligatorias y comprobadas

Por cada criterio, el modelo tiene que copiar de una a tres frases **literales** de la respuesta que justifiquen la nota. El servidor comprueba que esas frases están de verdad en la respuesta (sin importar mayúsculas, tildes o puntos suspensivos):

- Una cita que no aparece en la respuesta se descarta. El feedback nunca atribuye al candidato algo que no escribió.
- Si un criterio se queda sin ninguna cita válida, su nota no puede pasar de 40, y el feedback lo dice.

- Si el modelo se salta un criterio, cuenta 0 y se avisa («el corrector no puntuó este criterio»).

4.5 La nota final la calcula el servidor

Ejemplo resuelto: análisis de churn

Respuesta del candidato: *«El churn sube al 7,2 % este trimestre. La causa es el onboarding: los clientes no activan la cuenta. Propongo un onboarding guiado en 30 días con responsable de Customer Success y medir la activación semanal.»*

Criterio	Peso	Nota	Cita comprobada
Interpretación de los datos	25	80	«El churn sube al 7,2 % este trimestre»
Diagnóstico	25	60	«La causa es el onboarding»
Plan de acción priorizado	30	70	«onboarding guiado en 30 días con responsable…»
Justificación con datos	20	50	«medir la activación semanal»

Cuenta del servidor: (80 × 25 + 60 × 25 + 70 × 30 + 50 × 20) / 100 = **66**. Si el modelo hubiera propuesto un 90 global, se ignoraría.

4.6 Topes que aplica el servidor

El modelo marca tres banderas (si aborda el escenario, si es genérica y si copia el enunciado) y el servidor aplica el tope:

Situación	Nota máxima
No aborda el escenario	10
Copia o parafrasea el enunciado	15
Respuesta genérica, que valdría para cualquier caso	40
Grabación corregida sin transcripción	60
Señal leve de manipulación (ya existía)	60

4.7 Feedback que sirve para mejorar

Cada criterio llega al candidato con este formato, y al final hay un resumen y un siguiente paso:

Plan de acción priorizado · 70

Cita: «onboarding guiado en 30 días con responsable de Customer Success». Falta: priorizar entre varias acciones. Para subir: ordena tres acciones por impacto y di cuál harías primero.

4.8 Clasificaciones sin IA y descontando el azar

Los ejercicios de clasificar (por ejemplo, ordenar tareas en «urgente» y «puede esperar») se corrigen en el servidor con la solución oficial. Lo que diga el navegador sobre cuál era la correcta se ignora. Como con dos categorías se acierta la mitad eligiendo al azar, la nota descuenta ese azar:

Fórmula y ejemplos

nota = (acierto − 1/k) / (1 − 1/k) × 100, donde k es el número de categorías.

Con 2 categorías: 8 de 8 bien da **100**; 7 de 8 da **75**; 6 de 8 da **50**; 4 de 8 (lo que sale al azar) da **0**.

Ventajas: no se puede hacer trampa, la nota es exacta y no se gasta ninguna llamada a la IA en casi un tercio de los ejercicios.

4.9 Compatibilidad y pruebas

Si el modelo devuelve el formato antiguo, se usa como antes. El modo «crudo» del banco de pruebas del TFM no cambia, así que sus cifras siguen siendo válidas para lo que miden. Cada recibo lleva la versión 2.1.0, de modo que siempre se sabe con qué rúbrica se puso cada nota. Los tests nuevos están en *tests/corrector-v21.test.js* (138 tests en total, todos en verde).

5. Límites de la versión 2.1: lo que todavía no sabemos

Conviene ser honestos con lo que esta versión aún no ha demostrado:

Límite	Por qué importa	Cómo se resuelve
No se ha probado con el modelo real	Los tests simulan la respuesta del modelo. No sabemos si cita bien o si respeta el formato en todos los casos.	Corregir 20–30 respuestas reales y revisarlas a mano (propuesta A1).
El tope de 40 sin pruebas puede ser injusto	Si el modelo parafrasea en vez de copiar literalmente, se castiga al candidato por un fallo del corrector.	Medir el porcentaje de citas descartadas. Si supera el 10 %, relajar la comprobación o pedir las citas en un paso previo (C1).
Descontar el azar es exigente	Un 6 de 8 da 50, cuando antes parecía un 75.	Decisión de producto: la propuesta es mantenerlo y explicarlo en pantalla.
Los indicadores salen de la guía	Algunas guías no están numeradas o son pobres.	Indicadores escritos a mano para los retos clave (B1).
Sube el coste por corrección	La salida es más larga (de 1.000 a 1.800 tokens como máximo).	Caché del prompt y revisión del coste real tras una semana (I1).

6. Propuestas para mejorar el corrector

Las propuestas están agrupadas por objetivo. Cada una indica qué es, por qué ayuda y el esfuerzo aproximado. Las marcadas como **prioridad 1** son las que recomendamos hacer primero.

A. Medir antes de seguir

A1 · Gold set del catálogo con notas humanas — prioridad 1

Preparar unas 30 respuestas sobre 5 retos reales de la web (un análisis, dos correos de Personas y equipo, un reto de sector y uno de comunicación), de excelente a mala, más 2 intentos de manipulación. Que la asesora de RRHH y uno de vosotros las puntúen por separado con la misma rúbrica.

Por qué ayuda: Es la única forma de saber si el corrector acierta. Permite hablar de acuerdo con personas, algo que hoy el informe no puede afirmar.

Esfuerzo: 2–3 días de redacción, más la sesión con la asesora.

A2 · Banco de pruebas v2 sobre el corrector real — prioridad 1

Que *npm run bench* llame al corrector de la web (modo v2) con el gold set del catálogo y mida: acuerdo de banda (kappa cuadrática), error medio, estabilidad (misma respuesta dos veces), porcentaje de citas descartadas, porcentaje de topes aplicados y coste por corrección.

Por qué ayuda: Cada cambio de prompt, rúbrica o modelo se puede comparar con números antes de publicarlo.

Esfuerzo: 2 días.

A3 · Pruebas de sesgo — prioridad 2

Corregir la misma respuesta con variaciones que no deberían cambiar la nota: más larga pero sin más contenido, con faltas de ortografía, en inglés, con estilo más informal. Si la nota se mueve más de 5 puntos, hay un sesgo que corregir.

Por qué ayuda: El corrector puede estar premiando la longitud o el estilo en vez del contenido sin que nos demos cuenta.

Esfuerzo: 1 día, reutilizando el banco v2.

B. Rúbricas más ricas

B1 · Indicadores escritos por expertos para los retos clave — prioridad 1

Para cada reto de Personas y equipo, entre 3 y 5 indicadores observables, revisados por la asesora. Por ejemplo, en Liderazgo: «nombra un hecho concreto», «escucha antes de proponer», «acuerda un plazo», «no culpa a la persona».

Por qué ayuda: Los indicadores observables son lo que hace que dos correctores (humanos o IA) coincidan.

Esfuerzo: Medio día por reto; empezar por los 7 de Personas.

B2 · Descriptores por nivel en cada criterio — prioridad 2

Además de la escala general, describir qué es un 40, un 60 y un 80 en cada criterio concreto. Por ejemplo, en «Plan de acción»: 40 = lista de ideas sin orden; 60 = acciones con orden; 80 = acciones con orden, responsable y métrica.

Por qué ayuda: Reduce la ambigüedad entre tramos, que es donde más discrepan los correctores.

Esfuerzo: 1–2 días para los tres tipos de ejercicio.

B3 · Rúbrica según el nivel del reto — prioridad 3

Los ejercicios tienen dificultad básica, intermedia o avanzada. Ajustar las expectativas: en uno básico, un plan con dos acciones bien elegidas puede ser un 80.

Por qué ayuda: Hoy se exige lo mismo en todos los niveles, lo que penaliza a quien hace bien un reto básico.

Esfuerzo: 1 día.

B4 · Errores de fondo como penalización explícita — prioridad 3

Lista de errores graves por tipo (una decisión poco ética, un dato inventado, culpar a una persona en público) que restan puntos fijos.

Por qué ayuda: Un error grave puede quedar escondido en una media de criterios que, por lo demás, están bien.

Esfuerzo: 1 día.

C. Técnica de corrección

C1 · Corrección en dos pasadas — prioridad 2

Primera pasada: el modelo solo extrae evidencias (citas) e indicadores cumplidos, sin poner nota. Segunda pasada: puntúa a partir de esas evidencias.

Por qué ayuda: Separar «qué hay» de «cuánto vale» reduce las notas por impresión general y hace el feedback más concreto.

Esfuerzo: 2 días. Coste: dos llamadas por corrección (se compensa en parte con la caché del prompt).

C2 · Ejemplos calibrados en el prompt — prioridad 2

Incluir, por tipo de ejercicio, una respuesta floja y una buena ya puntuadas con su justificación.

Por qué ayuda: Es la forma más eficaz de que el modelo use la escala igual que nosotros.

Esfuerzo: 1 día. Unos 1.500 tokens más por corrección (se reducen con caché).

C3 · Doble corrección cerca de los cortes — prioridad 2

Si la nota cae a menos de 3 puntos de un corte de banda (por ejemplo, entre 57 y 63) o si algún criterio quedó limitado por falta de pruebas, se corrige otra vez. Si las dos notas difieren más de 10 puntos, pasa a revisión humana.

Por qué ayuda: Las notas cerca de un corte son las que cambian decisiones; ahí merece la pena gastar una llamada más.

Esfuerzo: 1 día.

C4 · Salida con formato garantizado — prioridad 2

Usar la herramienta de salida estructurada de la API (un esquema JSON) en vez de pedir «responde solo con JSON».

Por qué ayuda: Elimina los fallos de formato y obliga a que estén todos los criterios.

Esfuerzo: Medio día.

C5 · Comprobación de coherencia — prioridad 3

El servidor compara la nota de cada criterio con los indicadores cumplidos: un 85 con cero indicadores cumplidos, o un 20 con todos cumplidos, se marca para revisión.

Por qué ayuda: Detecta automáticamente las correcciones raras sin revisar todas a mano.

Esfuerzo: Medio día.

D. Contra la trampa

D1 · Variantes de cada reto — prioridad 2

Para cada ejercicio, varias versiones con cifras, nombres o contexto distintos (por ejemplo, un churn del 7,2 % o del 5,8 %). El servidor asigna una al azar.

Por qué ayuda: Hoy los retos son fijos: quien repite se aprende el ejercicio, y las respuestas se pueden compartir.

Esfuerzo: Continuo. Empezar por los 20 retos más usados.

D2 · Política de reintentos — prioridad 1

Un plazo entre intentos del mismo reto (por ejemplo, 30 días) y el número de intentos visible para la empresa.

Por qué ayuda: Hoy cuenta la mejor nota y no hay límite de intentos: la nota mide práctica, no competencia.

Esfuerzo: 1 día.

D3 · Detección de respuestas copiadas — prioridad 3

Comparar cada respuesta con las anteriores del mismo ejercicio. Si son casi iguales, se marca para revisión, sin penalizar automáticamente.

Por qué ayuda: Si alguien publica respuestas buenas, se detecta pronto.

Esfuerzo: 1–2 días.

E. Justicia y transparencia

E1 · Revisión humana de verdad — prioridad 1

Convertir «Pedir revisión» (hoy abre un correo) en una cola con estado, plazo de respuesta y registro de quién revisó y qué cambió. Más una muestra aleatoria del 5–10 % revisada cada semana.

Por qué ayuda: El Reglamento de IA y el RGPD (artículo 22) piden intervención humana real en decisiones automatizadas que afectan a personas.

Esfuerzo: 2–3 días.

E2 · Hoja de transparencia para el candidato — prioridad 2

Una página que explique qué se evalúa, cómo corrige la IA, qué ve la empresa y cómo pedir revisión.

Por qué ayuda: Genera confianza y es parte de las obligaciones de un sistema de alto riesgo.

Esfuerzo: 1 día.

E3 · Ajustes de accesibilidad — prioridad 3

Tiempo extra a petición en los retos con cronómetro y compatibilidad con lector de pantalla.

Por qué ayuda: Que la nota mida la competencia y no una dificultad ajena al puesto.

Esfuerzo: 1–2 días.

F. Mejor feedback para el candidato

F1 · Resultado como lista de comprobación — prioridad 2

Mostrar en la pantalla de resultado los indicadores cumplidos y los que faltan como una lista visual, y resaltar en su propio texto las frases citadas.

Por qué ayuda: El candidato ve exactamente qué hizo bien y qué le faltó, en vez de leer un párrafo.

Esfuerzo: 1–2 días (la información ya llega desde el servidor).

F2 · Comparación con su intento anterior — prioridad 3

Si repite un reto, enseñar qué criterios subieron y cuáles bajaron.

Por qué ayuda: Convierte el reto en aprendizaje y le da motivos para volver.

Esfuerzo: 1 día.

F3 · Plan de práctica — prioridad 3

A partir de sus criterios más débiles en todos los retos, recomendar los dos siguientes retos que más le ayudarían.

Por qué ayuda: Mejora la retención y llena el pool de candidatos con más evidencia.

Esfuerzo: 1–2 días.

G. Mejor información para la empresa

G1 · Bandas en vez del número exacto — prioridad 2

Enseñar Insuficiente / Aceptable / Bueno / Muy bueno, con el número disponible al pasar el ratón.

Por qué ayuda: Es lo que se puede garantizar: distinguir «bueno» de «aceptable» sí, acertar el 74 exacto no.

Esfuerzo: Medio día.

G2 · «Por qué este 78» — prioridad 2

En la ficha anónima, mostrar por cada competencia los indicadores cumplidos y una cita (si el candidato lo autoriza).

Por qué ayuda: La empresa compra evidencia, no un número. Es nuestro argumento principal.

Esfuerzo: 1–2 días.

G3 · Contexto de la nota — prioridad 3

Junto a cada nota: fecha, número de intentos, versión del corrector y si una persona la revisó.

Por qué ayuda: Una nota sin contexto vale menos.

Esfuerzo: Medio día.

H. Nuevos tipos de corrección

H1 · Transcripción del audio — prioridad 1

Transcribir la grabación antes de corregirla, con un servicio de voz a texto, y corregir el texto con la rúbrica de comunicación.

Por qué ayuda: Hoy el corrector solo recibe «[Grabación de N segundos]» y puede poner hasta 60 sin haber oído nada.

Esfuerzo: 2–3 días, más el coste del servicio.

H2 · Clasificación con justificación — prioridad 2

Después de clasificar, una frase: «¿Por qué esta es tu prioridad número 1?». La corrige la IA con un criterio de comprensión.

Por qué ayuda: Distingue a quien acierta por intuición de quien entiende la prioridad.

Esfuerzo: 1 día.

H3 · Repregunta adaptativa — prioridad 3

Tras la primera respuesta, el corrector hace una pregunta de seguimiento sobre el criterio más débil (por ejemplo, «¿y si el presupuesto se reduce a la mitad?»). La nota combina las dos respuestas.

Por qué ayuda: Se parece a una entrevista real y es mucho más difícil de preparar de memoria o de copiar.

Esfuerzo: 3–4 días.

H4 · Retos de oferta en el servidor — prioridad 2

Pasar los ejercicios específicos de las ofertas al catálogo del servidor, con su rúbrica e indicadores.

Por qué ayuda: Hoy se corrigen con el texto que manda el navegador y no se pueden verificar.

Esfuerzo: 1–2 días.

I. Coste y operación

I1 · Caché del prompt — prioridad 2

La parte fija del prompt (reglas, escala, rúbrica del tipo de ejercicio) es igual en muchas correcciones. La API de Anthropic permite guardarla en caché, y leerla de la caché cuesta una fracción del precio normal.

Por qué ayuda: Compensa el coste extra de la v2.1 y de los ejemplos calibrados.

Esfuerzo: Medio día.

I2 · Panel de salud del corrector — prioridad 2

En el backoffice: coste medio, tiempo medio, porcentaje de citas descartadas, porcentaje de topes, porcentaje de dobles correcciones y de revisiones humanas, por semana.

Por qué ayuda: Si algo se degrada (por ejemplo, el modelo empieza a parafrasear las citas), se ve en días y no en meses.

Esfuerzo: 1–2 días.

I3 · Versionado y recorrección — prioridad 3

Guardar la versión del corrector con cada nota (ya se hace en el recibo) y, al cambiar de versión, no mezclar notas de versiones distintas sin indicarlo. Si hace falta, recorregir las respuestas guardadas.

Por qué ayuda: Una nota de la v2.0 y otra de la v2.1 no son comparables.

Esfuerzo: 1 día.

I4 · Probar un modelo más reciente — prioridad 3

Comparar con el banco v2 el modelo actual (claude-sonnet-4-6) con uno más reciente, en acuerdo, estabilidad y coste, antes de cambiar.

Por qué ayuda: Puede mejorar la calidad o bajar el coste, pero las cifras del TFM están calibradas con el modelo actual.

Esfuerzo: 1 día, una vez exista el banco v2.

7. Hoja de ruta propuesta

Fase	Qué	Duración orientativa	Resultado
0 · Ya	Configurar EVAL_SIGNING_SECRET. Publicar la v2.1.	1 día	Notas verificadas en producción.
1 · Medir	A1 gold set con la asesora · A2 banco v2 · revisar 20–30 correcciones reales de la v2.1.	1–2 semanas	Sabemos cuánto acierta el corrector.
2 · Concretar	B1 indicadores de Personas · C2 ejemplos calibrados · C4 formato garantizado · D2 reintentos · H1 audio.	2 semanas	Feedback más concreto y notas más estables.
3 · Defender	C3 doble corrección · E1 revisión humana · G1 bandas · G2 «por qué este 78» · I2 panel de salud.	2 semanas	Notas que se pueden explicar a una empresa y a un candidato.
4 · Escalar	C1 dos pasadas · D1 variantes · H2 y H3 · H4 retos de oferta · I1 caché · I4 modelo.	Continuo	Más difícil de copiar, más barato y más parecido a una entrevista.

8. Decisiones pendientes

Decisión	Recomendación
¿Descontamos el azar en las clasificaciones?	Sí, explicándolo en la pantalla de resultado.
¿Enseñamos bandas a la empresa en vez del número exacto?	Sí, con el número disponible al pasar el ratón.
¿Quién pone las notas humanas del gold set?	La asesora y uno de vosotros dos, por separado.
¿Plazo entre intentos del mismo reto?	30 días, con el número de intentos visible.
¿Mantenemos el tope de 40 sin pruebas?	Sí, pero revisarlo con el porcentaje de citas descartadas del banco v2.

Anexo: dónde está cada cosa

Fichero	Qué contiene
netlify/functions/lib/evaluator.js	Reglas del prompt, rúbricas (RUBRICAS), escala (NIVELES), topes (TOPES), indicadores, cálculo de la nota (puntuar) y corrección de clasificaciones (corregirDecision).
netlify/functions/lib/handlers/evaluate-exercise.js	La función que corrige: enunciado oficial, filtro anti-manipulación, llamada al modelo y recibo firmado.
netlify/functions/lib/catalogo-retos.json	Copia de los 103 retos para el servidor. Se regenera con npm run catalogo; un test avisa si se desincroniza.
netlify/functions/lib/handlers/save-evaluation.js	Guarda la nota y decide si está verificada.
tests/corrector-v21.test.js	Tests de la v2.1: pesos, citas, topes, clasificaciones e indicadores.
docs/Cambios_prereunion/06_corrector.md	Versión corta de este documento, en el repositorio.